

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN



ĐỒ ÁN 03:
BÁO CÁO NGHIÊN CỨU VỀ
CÂY QUYẾT ĐỊNH

Giảng viên: Bùi Tiến Lên
Lê Nhật Nam
Võ Nhật Tân

Sinh viên: Lưu Huy Minh Quang – 23127016
Trần Cẩm Huy – 23127056
Trương Quốc Cường – 23127333
Nguyễn Tấn Phát – 23127449

Thành phố Hồ Chí Minh, 27 Tháng 08 Năm 2025

Mục lục

1	Giới thiệu	3
1.1	Bối cảnh và động lực	3
1.1.1	Bối cảnh	3
1.1.2	Giải thích phản thực (Counterfactual Explanations)	3
1.1.3	Hạn chế của CE hiện tại	3
1.2	Mục tiêu nghiên cứu	3
1.3	Đóng góp chính	4
1.4	Cấu trúc báo cáo	4
2	Các Công Trình Liên Quan	5
2.1	Nghiên cứu về cây quyết định	5
2.2	So sánh các hướng tiếp cận trước đó	5
2.2.1	Tiêu chí đánh giá	5
2.2.2	Phân tích chi tiết	5
2.3	Khoảng trống nghiên cứu	6
2.4	Vị trí nghiên cứu trong bối cảnh rộng hơn	6
3	Kiến thức nền tảng	7
3.1	Cây quyết định	7
3.1.1	Định nghĩa và cấu trúc	7
3.1.2	Tiêu chí phân chia	7
3.2	Cơ sở toán học	7
3.2.1	Ký hiệu cơ bản	7
3.2.2	Giải thích phản thực (CE)	8
3.2.3	CE cá thể và CE nhóm	8
3.2.4	CE nhóm với hàm mục tiêu g_γ	8
3.3	Cây giải thích phản thực (CET)	8
3.4	Thuật toán và kỹ thuật liên quan	8
3.5	Cơ sở lý thuyết cần thiết	9
4	Phương pháp nghiên cứu	10
4.1	Phương pháp đề xuất	10
4.2	Mô tả thuật toán	11
4.3	Phân tích lý thuyết	12
4.4	Các khía cạnh đổi mới	12
5	Thực nghiệm và Phân tích kết quả	13
5.1	Thiết lập thực nghiệm và bộ dữ liệu	13
5.2	Chỉ số đánh giá và phương pháp so sánh	13
5.3	Phân tích và diễn giải kết quả	13
5.4	So sánh hiệu năng và ý nghĩa thống kê	14
5.4.1	Complexity (Logistic Regression)	14
5.4.2	Complexity (LightGBM)	16
5.4.3	Convergence (Logistic Regression)	18
5.4.4	User Study	20
6	Kết luận và Định hướng nghiên cứu	22
6.1	Tóm tắt các phát hiện và đóng góp chính	22
6.2	Ưu điểm và hạn chế của phương pháp	22
6.3	Ý nghĩa đối với lĩnh vực	22
6.4	Định hướng nghiên cứu trong tương lai	22

Thông tin chung

Bài báo phụ trách

Counterfactual Explanation Trees: Transparent and Consistent Actionable Recourse with Decision Trees

Thông tin thành viên

Nhóm: 07

MSSV	Họ tên	Lớp
23127016	Lưu Huy Minh Quang	23CLC03
23127056	Trần Cẩm Huy	23CLC03
23127333	Trương Quốc Cường	23CLC03
23127449	Nguyễn Tấn Phát	23CLC03

Bảng công việc

Họ tên	Công việc
Lưu Huy Minh Quang	Tóm tắt phần Thực nghiệm và phân tích kết quả
	Chạy thử nghiệm và so sánh kết quả
	Làm slide phần Yêu cầu và cách tiếp cận
Trần Cẩm Huy	Tóm tắt phần Giới thiệu
	Tóm tắt phần Kiến thức nền tảng
	Thiết lập môi trường chạy code
	Làm slide phần Kiến thức nền tảng và Tổng quan đóng góp
Trương Quốc Cường	Tóm tắt phần Các công trình liên quan
	Tóm tắt phần Tổng kết và định hướng nghiên cứu
	Phân tích code
	Làm slide phần Mục tiêu nghiên cứu
Nguyễn Tấn Phát	Tóm tắt phần Phương pháp nghiên cứu
	Trực quan hóa kết quả từ thử nghiệm
	Làm slide phần Phương pháp đề xuất

Chương 1

Giới thiệu

1.1 Bối cảnh và động lực

1.1.1 Bối cảnh

Trong những năm gần đây, các mô hình học máy phức tạp như mạng nơ-ron sâu và phương pháp tập hợp cây đã được ứng dụng rộng rãi trong các quyết định quan trọng như chẩn đoán y tế, tuyển dụng và phê duyệt tín dụng. Mặc dù đạt độ chính xác dự đoán cao, các mô hình này thường thiếu tính giải thích, gây khó khăn cho việc hiểu và tin tưởng vào kết quả (Doshi-Velez and Kim 2017).


1.1.2 Giải thích phản thực (Counterfactual Explanations)

Một hướng tiếp cận phổ biến nhằm tăng tính minh bạch là các phương pháp giải thích cục bộ hậu nghiệm, đặc biệt là Giải thích phản thực (Counterfactual Explanations – CE) (Wachter và cộng sự 2018). CE đưa ra các hành động khả thi dưới dạng một vector nhiễu loạn giúp cá nhân thay đổi dự đoán sang kết quả mong muốn, ví dụ giảm chỉ số BMI để giảm nguy cơ tiểu đường. Quá trình này thường được mô hình hóa thành bài toán tối ưu, nhằm tìm hành động có chi phí thấp nhất nhưng vẫn đạt được kết quả mong muốn, còn được gọi là bài toán Giải pháp khắc phục khả thi (Actionable Recourse) (Ustun và cộng sự 2019).

1.1.3 Hạn chế của CE hiện tại

Các phương pháp CE hiện nay chủ yếu tập trung vào từng trường hợp riêng lẻ. Trong thực tế, nhiều hành động có thể tác động đồng thời lên nhiều cá nhân, ví dụ khi doanh nghiệp áp dụng chính sách thăng chức hoặc tăng lương để giảm nguy cơ nghỉ việc của nhân viên. Trong bối cảnh này, việc gán hành động cần đáp ứng hai yêu cầu then chốt:

1. **Tính minh bạch:** Quy trình gán hành động phải được giải thích rõ ràng, tránh gây ra sự chênh lệch thiếu công bằng.
2. **Tính nhất quán:** Các lý do gán hành động phải thống nhất, không mâu thuẫn giữa các trường hợp tương tự.



Hình 1.1: Ví dụ về CET trên tập dữ liệu *IBM HR Analytics Employee Attrition* (Kaggle 2017)

Các framework CE hiện hành và các phương pháp giải thích cục bộ khác chưa đáp ứng được hai yêu cầu này, do không xét đến toàn bộ không gian đầu vào (Ribeiro và cộng sự 2018).

1.2 Mục tiêu nghiên cứu

Để khắc phục hạn chế nêu trên, nghiên cứu này đề xuất **Cây Giải thích phản thực (Counterfactual Explanation Tree - CET)**. CET phân chia không gian đầu vào thành các miền con dễ hiểu, mỗi miền được gán một hành động

thích hợp. Nhờ tính chất của cây quyết định, CET mang lại hai lợi thế:

1. **Tính minh bạch:** Quy tắc gán hành động được thể hiện dưới dạng cấu trúc cây dễ diễn giải, tương ứng với các luật if-then-else.
2. **Tính nhất quán:** Mỗi trường hợp chỉ thuộc một miền duy nhất, đảm bảo gán đúng một cặp hành động-lý do, tránh mâu thuẫn.

1.3 Đóng góp chính

Nghiên cứu này đưa ra các đóng góp sau:

1. **Đề xuất CET:** Xây dựng cây quyết định gán hành động một cách minh bạch và nhất quán trên toàn bộ không gian đầu vào.
2. **Mô hình hóa và thuật toán:** Biểu diễn bài toán học CET dưới dạng tối ưu hóa và phát triển thuật toán tìm kiếm cục bộ ngẫu nhiên kết hợp chiến lược cắt tỉa dựa trên cận hàm mục tiêu.
3. **Thực nghiệm và nghiên cứu người dùng:** Thử nghiệm trên các bộ dữ liệu công khai cho thấy CET hiệu quả và dễ hiểu hơn so với các phương pháp hiện có. Nghiên cứu người dùng cũng chứng minh CET có khả năng gán cặp hành động-lý do rõ ràng và duy nhất.
4. **Tính linh hoạt:** CET có thể kết hợp với nhiều hàm chi phí khác nhau (ví dụ độ dịch chuyển bách phân vị lớn nhất (Ustun và cộng sự 2019)) và áp dụng cho cả các trường hợp chưa xuất hiện trong tập huấn luyện, tương tự các cơ chế giải thích phân bố (Chen và cộng sự 2018).

1.4 Cấu trúc báo cáo

Báo cáo được tổ chức thành sáu chương:

Chương 1: Giới thiệu - Trình bày bối cảnh, động lực, mục tiêu và đóng góp chính của nghiên cứu.

Chương 2: Các công trình liên quan - Tổng quan các nghiên cứu về cây quyết định và Giải thích phản thực, chỉ ra khoảng trống nghiên cứu và vị trí của đề tài.

Chương 3: Kiến thức nền tảng - Trình bày các khái niệm cơ bản, cơ sở toán học và thuật toán được sử dụng.

Chương 4: Phương pháp nghiên cứu - Mô tả chi tiết phương pháp CET, thuật toán, mã giả và phân tích lý thuyết.

Chương 5: Thực nghiệm và phân tích kết quả - Trình bày thiết lập thực nghiệm, bộ dữ liệu, chỉ số đánh giá và phân tích kết quả.

Chương 6: Kết luận và định hướng - Tóm tắt đóng góp chính, hạn chế và hướng phát triển trong tương lai.

Chương 2

Các Công Trình Liên Quan

2.1 Nghiên cứu về cây quyết định

Cây quyết định (Decision Tree – DT) là một trong những mô hình học máy cơ bản, được ưa chuộng nhờ tính minh bạch và dễ hiểu. Các thuật toán kinh điển như **CART** (Breiman và cộng sự 1984) và **ID3** (Quinlan 1986) xây dựng cây theo hướng *tham lam* (greedy): tại mỗi nút, đặc trưng được chọn dựa trên tiêu chí cục bộ (Gini impurity cho CART, information gain cho ID3), sau đó lá được gán nhãn theo đa số lớp hoặc quy tắc đơn giản khác.

Các nghiên cứu gần đây mở rộng cây quyết định cho các mục tiêu phi truyền thống, chẳng hạn *optimal trees* (Hu và cộng sự 2019; Aglin và cộng sự 2020) và tìm kiếm ngẫu nhiên (stochastic search). Những công trình này chứng minh DT có thể được điều chỉnh không chỉ để phân loại mà còn để giải các bài toán tối ưu có cấu trúc, đồng thời vẫn duy trì tính minh bạch.

2.2 So sánh các hướng tiếp cận trước đó

2.2.1 Tiêu chí đánh giá

Các phương pháp giải thích phản thực được so sánh theo bốn tiêu chí:

- **Mục tiêu tối ưu:** cục bộ (local) cho từng cá thể hay toàn cục (global) cho toàn bộ dữ liệu.
- **Phủ toàn cục:** mức độ đảm bảo mọi cá thể đều có hành động/lý do cụ thể.
- **Minh bạch:** khả năng diễn giải rõ ràng, dễ hiểu, và có lý do đi kèm.
- **Nhất quán:** tính thống nhất trong việc gán hành động cho các cá thể tương tự.

Bảng 2.1: So sánh các hướng tiếp cận

Phương pháp	Mục tiêu tối ưu	Phủ toàn cục	Minh bạch	Nhất quán
CE (Wachter và cộng sự 2018; Karimi và cộng sự 2021; Kanamori và cộng sự 2022; Schut và cộng sự 2021)	Local	Không	Có	Có
CE (Ustun và cộng sự 2019; Mothilal và cộng sự 2020)	Local	Không	Có	Có
ARes (Rawal and Lakkaraju 2020)	Global	Không	Không	Không
MAME (Ramamurthy và cộng sự 2020)	Global	Có	Có	Không
GIME (Gao và cộng sự 2021)	Global	Có	Có	Không
CET (Counterfactual Explanation Trees)	Global	Có	Có	Có

2.2.2 Phân tích chi tiết

1. **CE cục bộ** (Wachter và cộng sự 2018; Karimi và cộng sự 2021; Kanamori và cộng sự 2022; Schut và cộng sự 2021): Tối ưu chi phí để tìm hành động cho một cá thể duy nhất. Minh bạch và nhất quán ở cấp cá thể, nhưng không bao phủ toàn cục.
2. **CE cục bộ nâng cao** (Ustun và cộng sự 2019; Mothilal và cộng sự 2020): Sử dụng **MILO/MILP** để sinh hành động khả thi với ràng buộc ngân sách và hướng thay đổi. (DiCE) sinh nhiều hành động đa dạng. Tuy nhiên, cả hai vẫn chỉ ở mức local, chưa bao phủ toàn cục.
3. **ARes** (Rawal and Lakkaraju 2020): Học tập hợp luật hai tầng để cung cấp recourse toàn cục. Do giới hạn số và độ dài luật, nhiều điểm không được bao phủ; các luật có thể chồng lấn, dẫn đến thiếu minh bạch và nhất quán.
4. **MAME** (Ramamurthy và cộng sự 2020): Tổng hợp giải thích cục bộ bằng phân cụm phân cấp để tạo mẫu giải

thích chung. Đảm bảo phủ toàn cục và dễ hiểu, nhưng các cụm có thể chồng lấn, khiến một điểm dữ liệu có nhiều hành động khác nhau.

5. **GIME** (Gao và cộng sự 2021): Sử dụng *topic modeling* để nhóm đặc trưng thành chủ đề và giải thích dựa trên các chủ đề đó. Minh bạch và bao phủ toàn cục, song một điểm có thể liên quan đến nhiều chủ đề, gây thiếu nhất quán.
6. **CET (Counterfactual Explanation Trees)**: Phân hoạch toàn bộ không gian đầu vào bằng cây quyết định. Mỗi cá thể thuộc đúng một lá, được gán duy nhất một hành động–lý do, đảm bảo minh bạch, nhất quán và phủ toàn cục.

Nhận xét: So với CE cục bộ và các framework tổng hợp toàn cục (AReS, MAME, GIME), **CET** là phương pháp duy nhất đồng thời đảm bảo **minh bạch, nhất quán và phủ toàn cục**.

2.3 Khoảng trống nghiên cứu

CE cục bộ (Wachter và cộng sự 2018; Karimi và cộng sự 2021; Ustun và cộng sự 2019) mang lại giải thích chi tiết cho từng cá thể nhưng thiếu khả năng bao phủ toàn cục. Trong khi đó, các framework toàn cục như AReS, MAME và GIME cung cấp góc nhìn tổng thể nhưng thường thiếu minh bạch hoặc nhất quán.

Do đó, khoảng trống nghiên cứu nằm ở việc phát triển một phương pháp vừa đảm bảo **toàn cục**, vừa duy trì **minh bạch và nhất quán**. CET được đề xuất để lấp đầy khoảng trống này thông qua cấu trúc cây quyết định kết hợp tối ưu hóa toàn cục.

2.4 Vị trí nghiên cứu trong bối cảnh rộng hơn

CET khắc phục đồng thời hạn chế của phương pháp cục bộ và toàn cục bằng hai ý tưởng chính:

1. **Phân hoạch không gian đầu vào:** mỗi đường đi từ gốc đến lá định nghĩa một luật rõ ràng, giúp lý giải trực quan.
2. **Tối ưu hành động theo vùng:** mọi điểm trong cùng một lá nhận cùng một hành động duy nhất, đảm bảo nhất quán và phủ toàn cục.

Minh bạch: Quy tắc if-then-else trong cây thể hiện rõ lý do cho từng hành động.

Nhất quán: Mỗi điểm dữ liệu thuộc đúng một lá, do đó chỉ có một hành động duy nhất.

Phủ toàn cục: Cây phân hoạch toàn bộ không gian, mọi cá thể đều có hành động gợi ý.

Kết luận: CET là sự kết hợp giữa tính diễn giải của cây quyết định và tính linh hoạt của các phương pháp giải thích phản thực hiện đại, tạo thành một framework toàn diện cho giải thích vừa minh bạch vừa khả thi.

Chương 3

Kiến thức nền tảng

3.1 Cây quyết định

3.1.1 Định nghĩa và cấu trúc

Cây quyết định là một thuật toán học có giám sát, thường được xây dựng từ các quy tắc if-then-else và biểu diễn dưới dạng cây nhị phân. Mục tiêu là học một ánh xạ

$$f: \mathcal{X} \rightarrow \mathcal{Y}$$

gán đầu vào x thành nhãn hoặc giá trị dự đoán y (Russell and Norvig 2021).

Cấu trúc cơ bản:

- **Nút trong:** kiểm tra thuộc tính dữ liệu.
- **Nhánh:** giá trị khả dĩ của thuộc tính.
- **Nút lá:** quyết định cuối cùng.

3.1.2 Tiêu chí phân chia

Mục tiêu là chọn thuộc tính tối ưu để phân chia dữ liệu dựa trên mức độ hỗn tạp.

Phân loại:

- **Gini Impurity:**

$$G(p) = 1 - \sum_{i=1}^k p_i^2$$

- **Information Gain** dựa trên Entropy:

$$Entropy(S) = - \sum_{i=1}^k p_i \log_2(p_i)$$

$$Gain(S, A) = Entropy(S) - \sum_{v \in Values(A)} \frac{|S_v|}{|S|} Entropy(S_v)$$

Hồi quy:

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

3.2 Cơ sở toán học

3.2.1 Ký hiệu cơ bản

- Tập số nguyên: $[n] = \{1, \dots, n\}$.
- Hàm chỉ thị: $\mathbb{I}[\psi] = 1$ nếu ψ đúng, ngược lại 0.
- Miền: $\mathcal{X} \subseteq \mathbb{R}^D$, $\mathcal{Y} = \{-1, +1\}$.
- Bộ phân loại: $f: \mathcal{X} \rightarrow \mathcal{Y}$.
- Hành động: $a \in \mathbb{R}^D$.
- Hàm chi phí: $c(a|x) \geq 0$, $c(\mathbf{0}|x) = 0$.
- Mất mát 0-1: $l_{01}(\hat{y}, y) = \mathbb{I}[\hat{y} \neq y]$.
- Điểm không hợp lệ:

$$i_\gamma(a|x) := c(a|x) + \gamma \cdot l_{01}(f(x+a), +1).$$

3.2.2 Giải thích phản thực (CE)

CE tìm một nhiễu loạn a để thay đổi dự đoán sang nhãn mục tiêu y^* (Wachter và cộng sự 2018; Karimi và cộng sự 2021):

$$\min_{a \in \mathcal{A}} c(a|x) \quad \text{s.t.} \quad f(x+a) = y^*.$$

3.2.3 CE cá thể và CE nhóm

CE cá thể:

$$\min_{a \in \mathcal{A}(x)} c(a|x) \quad \text{sao cho} \quad f(x+a) = +1. \quad (1)$$

CE nhóm (naive extension):

$$a^* = \arg \min_{a \in \mathcal{A}(X)} \sum_{x \in X} c(a|x) \quad \text{sao cho} \quad f(x+a) = +1, \quad \forall x \in X. \quad (2)$$

Mệnh đề 1 (Cận trên chi phí). Với a^* nghiệm của (2) và $c^*(x)$ nghiệm của (1), ta có

$$c(a^*|x) - c^*(x) \leq c_x \cdot \|x - x^\circ\|, \quad x^\circ = \arg \min_{x \in \mathcal{X}} w^\top x.$$

Kết quả cho thấy ràng buộc (2) có thể gây chi phí cao, do bị chi phối bởi các điểm xa biên quyết định.

3.2.4 CE nhóm với hàm mục tiêu g_γ

Định nghĩa:

$$g_\gamma(a|X) = \sum_{x \in X} i_\gamma(a|x).$$

Bài toán 1 (CE nhóm).

$$\min_{a \in \mathcal{A}(X)} g_\gamma(a|X).$$

Mệnh đề 2 (Tính đơn điệu). Với $X = X_1 \cup X_2$, $X_1 \cap X_2 = \emptyset$:

$$g_\gamma(a_X^*|X) \geq g_\gamma(a_{X_1}^*|X_1) + g_\gamma(a_{X_2}^*|X_2).$$

Chứng minh. Theo định nghĩa g_γ , ta có

$$g_\gamma(a|X) = g_\gamma(a|X_1) + g_\gamma(a|X_2).$$

Vì $\mathcal{A}(X) \subseteq \mathcal{A}(X_1), \mathcal{A}(X_2)$ nên a_X^* khả thi cho X_1, X_2 . Suy ra bất đẳng thức. $\square$

3.3 Cây giải thích phản thực (CET)

Một CET $h: \mathcal{X} \rightarrow \mathcal{A}$ là cây quyết định gán mỗi x với một hành động a_l tại nút lá l :

$$h(x) = \sum_{l \in \mathcal{L}(h)} a_l \cdot \mathbb{I}[x \in r_l].$$

Quá trình học CET:

- (i) Xác định hành động hiệu quả cho nhóm cá thể.
- (ii) Xây dựng cây phân vùng cân bằng giữa hiệu quả và diễn giải.

Bài toán 2 (Học CET).

$$\min_{h \in \mathcal{H}} o_{\gamma, \lambda}(h|X) = \frac{1}{N} \sum_{x \in X} i_\gamma(h(x)|x) + \lambda \cdot |\mathcal{L}(h)|.$$

Trong đó $\lambda > 0$ điều chỉnh cân bằng giữa hiệu quả và độ phức tạp của cây.

3.4 Thuật toán và kỹ thuật liên quan

- **CE truyền thống:** Wachter và cộng sự (2018).
- **Actionable Recourse:** hành động khả thi, ví dụ MILO (Ustun và cộng sự 2019).
- **CE nhóm:** mở rộng CE cá thể (Karimi và cộng sự 2021).
- **Giải thích bằng cây:** đảm bảo minh bạch (Freitas 2014; Guidotti và cộng sự 2018).
- **Stochastic Local Search:** huấn luyện CET bằng sửa đổi ngẫu nhiên quy tắc phân nhánh kết hợp MILO (Kanamori và cộng sự 2022).

3.5 Cơ sở lý thuyết cần thiết

- **Hàm chi phí:** đo nỗ lực, ví dụ Max Percentile Shift (Ustun và cộng sự 2019).
- **Mất mát 0-1:**

$$l_{01}(\hat{y}, y) = \mathbb{I}[\hat{y} \neq y].$$

- **Điểm không hợp lệ:**

$$i_\gamma(a|x) = c(a|x) + \gamma \cdot l_{01}(f(x+a), +1).$$

- **Hàm mục tiêu CE nhóm:**

$$g_\gamma(a|X) = \sum_{x \in X} i_\gamma(a|x).$$

- **Tính chất CET:**

- *Minh bạch:* hành động gắn với quy tắc rõ ràng.
- *Nhất quán:* mỗi cá thể có đúng một cặp (hành động, lý do) (Kanamori và cộng sự 2022).

Chương 4

Phương pháp nghiên cứu

4.1 Phương pháp đề xuất

Counterfactual Explanation Tree (CET) là một framework mới để gán hành động (actions) cho nhiều instances đồng thời bằng cách sử dụng cây quyết định. Khác với các phương pháp Counterfactual Explanation (CE) truyền thống chỉ tập trung vào việc cung cấp hành động cho một instance đơn lẻ, CET được thiết kế để xử lý trường hợp cần gán hành động cho nhiều instances một cách minh bạch (transparent) và nhất quán (consistent).

CET là một phương pháp mới, kết hợp giữa giải thích phản thực và cây quyết định, nhằm cung cấp hành động khả thi cho nhiều instance cùng lúc một cách minh bạch và nhất quán. Các kết quả thực nghiệm và khảo sát người dùng cho thấy CET vượt trội so với các phương pháp hiện có về cả hiệu quả và khả năng giải thích.

Một thuật toán ngây thơ là chiến lược phân hoạch tham lam từ trên xuống như CART (Breiman et al., 1984), trong đó đệ quy xác định luật phân nhánh của mỗi nút trong để cải thiện nhiều nhất giá trị mục tiêu sau khi tách. Tuy nhiên, để xác định luật phân nhánh của mỗi nút trong, chúng ta cần giải Bài toán 1 cho số lượng luật phân nhánh ứng viên, điều này là không khả thi về mặt tính toán. Trong các thí nghiệm sơ bộ, các quan sát cho thấy rằng phương pháp này không tạo ra một cây quyết định có chất lượng tốt xét theo điểm số không hợp lệ i_r . Nguyên nhân là do phương pháp này thường chọn một luật phân nhánh không phù hợp ở một nút gần gốc và do đó không phân tách được các mẫu đầu vào X theo cách mà chúng được gán một hành động hiệu quả trong mỗi nút lá mà chúng đi đến.

Từ những quan sát trên, nghiên cứu này đề xuất một thuật toán dựa trên tìm kiếm cục bộ ngẫu nhiên (stochastic local search) cho Bài toán 2. Tìm kiếm cục bộ ngẫu nhiên đã được chứng minh là phù hợp cho việc học các mô hình quy tắc phi chuẩn (Wang, 2019; Pan et al., 2020). Thuật toán bao gồm hai bước: xác định luật phân nhánh của các nút trong bằng cách sử dụng tìm kiếm cục bộ ngẫu nhiên, và tối ưu hóa một hành động được gán cho mỗi nút lá bằng cách giải Bài toán 1 độc lập.

4.2 Mô tả thuật toán

Algorithm 1 Tìm kiếm cục bộ ngẫu nhiên cho CET

Đầu vào: tập các mẫu X , tham số cân bằng γ, λ , tập các luật phân nhánh ứng viên $\mathcal{R}$, số vòng lặp tối đa T , và điều kiện chấp nhận **ACCEPT**.

Đầu ra: CET h^* .

```

1:  $h^{(0)} \leftarrow$  Sinh ngẫu nhiên một nghiệm khởi tạo;
2:  $h^* \leftarrow h^{(0)}$ ;
3: for  $t = 1, 2, \dots, T$  do
4:    $\delta \sim \text{RANDOM}()$ ;
5:   if  $\delta \leq 1/3$  và  $|\mathcal{L}(h^{(t-1)})| < (\gamma + \lambda)/\lambda$  then
6:      $h^{(t)} \leftarrow$  Chèn ngẫu nhiên một nút với một luật  $r \in \mathcal{R}$  vào  $h^{(t-1)}$ ;
7:   else if  $\delta \leq 2/3$  then
8:      $h^{(t)} \leftarrow$  Xóa ngẫu nhiên một nút từ  $h^{(t-1)}$ ;
9:   else
10:     $h^{(t)} \leftarrow$  Thay thế ngẫu nhiên luật của một nút trong  $h^{(t-1)}$  bằng một luật khác  $r \in \mathcal{R}$ ;
11:   end if
12:   for  $\ell \in \mathcal{L}(h^{(t)})$  do
13:      $a_\ell^{(t)} \leftarrow \operatorname{argmin}_{a \in A(X_\ell^{(t)})} g_\gamma(a \mid X_\ell^{(t)})$ ;
14:   end for
15:   if ACCEPT( $t, h^{(t-1)}, h^{(t)}$ ) là False then
16:      $h^{(t)} \leftarrow h^{(t-1)}$ ;
17:   end if
18:    $h^* \leftarrow \operatorname{argmin}_{h \in \{h^*, h^{(t)}\}} o_{\gamma, \lambda}(h \mid X)$ ;
19: end for
20: return  $h^*$ ;

```

Nghiên cứu này chỉ ra một cận trên của kích thước lá $|\mathcal{L}(h^*)|$ của một CET tối ưu h^* như sau.

Định lý 1 (Giới hạn kích thước lá). *Gọi h^* là nghiệm tối ưu cho Bài toán 2, tức là*

$$h^* = \operatorname{argmin}_{h \in \mathcal{H}} o_{\gamma, \lambda}(h \mid X).$$

Khi đó, ta có:

$$|\mathcal{L}(h^*)| \leq \frac{\gamma + \lambda}{\lambda}.$$

Định lý 1 chỉ ra rằng kích thước lá tối ưu $|\mathcal{L}(h^*)|$ bị chặn trên bởi một hằng số được xác định bởi các tham số cân bằng γ và λ . Nó cũng gợi ý cho chúng ta cách xác định các tham số cân bằng γ và λ , λ càng lớn thì cây càng nhỏ.

Trong Thuật toán 1, đầu tiên cần sinh ngẫu nhiên một nghiệm khởi tạo $h^{(0)}$, sau đó tuần tự cập nhật nó cho đến khi số vòng lặp đạt đến một số nguyên $T \in \mathbb{N}$. Mỗi vòng lặp $t \in [T]$ gồm hai bước cập nhật.

Trước hết, cập nhật nghiệm trước đó $h^{(t-1)}$ thành $h^{(t)}$ bằng chiến lược tìm kiếm cục bộ ngẫu nhiên. Việc cập nhật được thực hiện bằng ba phép chỉnh sửa với xác suất xấp xỉ bằng nhau:

1. **Chèn** một nút trong với luật ngẫu nhiên $r \in \mathcal{R}$ vào một vị trí ngẫu nhiên của $h^{(t-1)}$,
2. **Xóa** ngẫu nhiên một nút của $h^{(t-1)}$,
3. **Thay thế** ngẫu nhiên luật của một nút ngẫu nhiên của $h^{(t-1)}$ bằng một luật khác $r \in \mathcal{R}$.

Lưu ý rằng việc cắt tỉa không gian tìm kiếm được thực hiện bằng cách loại bỏ thao tác chèn khi kích thước lá $|\mathcal{L}(h^{(t-1)})|$ vượt quá cận trên của Định lý 1.

Thứ hai, tối ưu một hành động $a_l^{(t)}$ của mỗi lá $l \in \mathcal{L}(h^{(t)})$ bằng cách giải Bài toán 1 cho các mẫu $X_l^{(t)}$ đi đến lá đó. Trong mỗi vòng lặp, thao tác cập nhật được chấp nhận phụ thuộc vào một điều kiện chấp nhận nhất định **ACCEPT**($t, h^{(t-1)}, h^{(t)}$). Theo các nghiên cứu trước (Wang, 2019; Pan et al., 2020), nghiên cứu này chấp nhận nó với xác suất:

$$p(t) = \exp \left(\frac{o_{\gamma, \lambda}(h^{(t-1)}) - o_{\gamma, \lambda}(h^{(t)})}{C_0^{1 - \frac{t}{T}}} \right),$$

trong đó C_0 là nhiệt độ cơ bản của thuật toán mô phỏng quá trình tôi luyện (simulated annealing). Xác suất $p(t)$ sẽ giảm dần theo số vòng lặp t .

4.3 Phân tích lý thuyết

Nghiên cứu này trình bày một thuật toán cho Bài toán 2 dựa trên tìm kiếm cục bộ ngẫu nhiên. Giả sử một tập hợp các luật phân nhánh ứng viên $\mathcal{R}$. Một phần tử $r \in \mathcal{R}$ là một mệnh đề liên quan đến một mẫu x , ví dụ $x_d \leq b$ cho đặc trưng liên tục hoặc $x_d = b$ cho đặc trưng rời rạc, trong đó $d \in [D]$ và $b \in \mathbb{R}$. Chúng ta có thể thu được $\mathcal{R}$ bằng một số kỹ thuật rời rạc hóa, như trong các nghiên cứu gần đây về cây quyết định (Hu et al., 2019; Aglin et al., 2020).

Với một CET $h \in \mathcal{H}$, đặt $X_l = \{x \in X \mid x \in r_l\}$ là tập các mẫu đi đến lá $l \in \mathcal{L}(h)$. Vì $\{r_l \mid l \in \mathcal{L}(h)\}$ là một phân hoạch của không gian đầu vào X , nên nó cũng phân hoạch X ; tức là, $\bigcup_{l \in \mathcal{L}(h)} X_l = X$ và $X_l \cap X_{l'} = \emptyset$ với mọi $l, l' \in \mathcal{L}(h)$. Do đó, chúng ta có thể viết lại mục tiêu học $o_{\gamma, \lambda}(h)$ như sau:

$$o_{\gamma, \lambda}(h) = \frac{1}{N} \sum_{l \in \mathcal{L}(h)} g_{\gamma}(a_l \mid X_l) + \lambda \cdot |\mathcal{L}(h)|.$$

Điều này cho thấy rằng nếu các luật phân nhánh của các nút trong h , tức là một phân hoạch của X , đã được xác định, thì ta có thể tối ưu hóa một hành động $a_l \in \mathcal{A}(X_l)$ gán cho mỗi lá $l \in \mathcal{L}(h)$ bằng cách giải Bài toán 1 một cách độc lập.

4.4 Các khía cạnh đổi mới

1. Tính minh bạch và nhất quán:

- CET đảm bảo mỗi instance nhận được một hành động duy nhất kèm luật giải thích rõ ràng.
- Khắc phục nhược điểm của các phương pháp dựa trên luật (như AReS) có thể gán nhiều hành động hoặc không gán được hành động nào.

2. Cân bằng hiệu quả và giải thích được: Tham số λ cho phép điều chỉnh số lượng hành động, cân bằng giữa độ chính xác và độ phức tạp của mô hình.

3. Khả năng tổng quát hóa: CET có thể áp dụng cho nhiều loại mô hình phân lớp (linear, tree ensemble, neural network) và hàm chi phí khác nhau.

4. Hiệu quả tính toán:

- Sử dụng MILO để giải bài toán tối ưu cho từng nhóm instance.
- Thuật toán stochastic local search kết hợp với ràng buộc lý thuyết giúp giảm không gian tìm kiếm.

Chương 5

Thực nghiệm và Phân tích kết quả

5.1 Thiết lập thực nghiệm và bộ dữ liệu

Các thí nghiệm được tiến hành nhằm kiểm chứng tính hiệu quả và khả năng diễn giải của *Counterfactual Explanation Tree* (CET).

- **Môi trường thực nghiệm:** Python 3.12, chạy trên Windows 11 với CPU Intel Core i5-12450H (12th Gen, 2.0GHz) và RAM 8GB.
- **Hàm chi phí:** sử dụng *Max Percentile Shift* (MPS) (Ustun và cộng sự 2019), được định nghĩa như sau:

$$c(a|x) = \max_{d \in [D]} |Q_d(x_d + a_d) - Q_d(x_d)|,$$

trong đó Q_d là hàm phân phối tích lũy (CDF) của thuộc tính d . MPS có ưu điểm bất biến theo thang đo và giới hạn trong $[0, 1]$, phù hợp để đánh giá hành động trên nhiều cá thể đồng thời.

- **Bộ dữ liệu:**
 - *IBM HR Analytics Employee Attrition* (Kaggle 2017) – dự đoán nguy cơ nghỉ việc của nhân viên.
 - *German Credit* (Becker and Kohavi 1996) – dự đoán rủi ro tín dụng.
 - *Diabetes* – dự đoán nguy cơ mắc bệnh tiểu đường.
- **Mô hình cơ sở:** LightGBM (Ke và cộng sự 2017) và Logistic Regression được huấn luyện làm bộ phân loại cơ sở.

5.2 Chỉ số đánh giá và phương pháp so sánh

- **Cost:** chi phí trung bình của các hành động gán.
- **Loss:** tỉ lệ lỗi (0–1 loss) khi hành động không thay đổi dự đoán theo hướng mong muốn.
- **Invalidity:** chỉ số tổng hợp phản ánh cả chi phí và lỗi.

Các phương pháp so sánh gồm:

- **Clustering:** gom cụm cá thể và gán hành động theo cụm.
- **AReS** (Rawal and Lakkaraju 2020): mô hình quy tắc hai tầng cho hành động.
- **CET:** phương pháp đề xuất.

Kết quả được báo cáo bằng **5-fold cross validation**.

5.3 Phân tích và diễn giải kết quả

Trên *Attrition dataset* với LightGBM:

- CET đạt chi phí thấp hơn AReS (0.383 so với 0.450) và chỉ số Invalidity cũng thấp hơn (0.701 so với 0.748).

Trên *German dataset* với LightGBM:

- CET cải thiện đáng kể chỉ số Invalidity (0.384 so với 0.732 của AReS), đồng thời chi phí cũng thấp hơn nhiều.

Với TabNet:

- CET vẫn duy trì hiệu quả vượt trội so với AReS và Clustering, chứng minh tính ổn định trên nhiều loại bộ phân loại.

Ví dụ trực quan từ Hình 1.1 minh họa rằng CET không chỉ đạt hiệu quả mà còn dễ giải thích. Chẳng hạn, một luật đơn giản được rút ra là:

“Hành động này hiệu quả cho 86% nhân viên làm việc ngoài giờ (OverTime).”

Điều này củng cố tính **minh bạch (transparency)** và **nhất quán (consistency)** trong gán hành động.

5.4 So sánh hiệu năng và ý nghĩa thống kê

- CET ổn định hơn so với AReS và Clustering, thể hiện qua Invalidity luôn thấp hơn trên cả hai bộ dữ liệu và hai loại mô hình.
- CET duy trì được sự cân bằng giữa **hiệu quả** (chi phí thấp, giảm rủi ro) và **khả năng diễn giải** (cấu trúc dạng cây).
- Kết quả **5-fold cross validation** cùng với sai số chuẩn nhỏ cho thấy kết quả có ý nghĩa thống kê, không phải do ngẫu nhiên.

Dưới đây là một số kết quả mà nhóm chạy được sau khi đã có một vài sự tinh giảm để phù hợp với cấu hình của máy tính.


Bảng 5.1: Performance Comparison for LightGBM Model

Method	Cost		Loss		Objective	
	Train	Test	Train	Test	Train	Test
Clustering	0.000 $\pm$ 0.00	1.000 $\pm$ 0.00	1.000 $\pm$ 0.00	0.000 $\pm$ 0.00	1.000 $\pm$ 0.00	1.000 $\pm$ 0.00
AReS	0.586 $\pm$ 0.02	0.090 $\pm$ 0.04	0.676 $\pm$ 0.03	0.622 $\pm$ 0.04	0.077 $\pm$ 0.03	0.699 $\pm$ 0.01
CET	0.474 $\pm$ 0.05	0.165 $\pm$ 0.07	0.639 $\pm$ 0.06	0.479 $\pm$ 0.06	0.181 $\pm$ 0.07	0.660 $\pm$ 0.06

Bảng 5.2: Runtime Comparison (seconds)

Dataset	Clustering	AReS	CET
Diabetes	12.8255 $\pm$ 3.6214	10.7791 $\pm$ 2.1756	3791.3269 $\pm$ 637.9354
Average	12.8255	10.7791	3791.3269


5.4.1 Complexity (Logistic Regression)



Hình 5.1: Complexity - Logistic Regression - Diabetes


- Cost:** CET và Clustering duy trì chi phí thấp hơn đáng kể so với AReS (luôn cao khoảng 0.6). Trên tập kiểm thử, CET cho thấy chi phí ổn định và thấp, chứng tỏ các hành động được gợi ý hợp lý hơn.
- Loss:** CET giảm dần tỉ lệ lỗi khi số hành động tăng, thể hiện khả năng tận dụng tốt hơn độ phức tạp. Clustering dao động mạnh, đặc biệt trên tập kiểm thử, trong khi AReS có Loss thấp nhưng đi kèm Cost cao, dẫn đến Invalidity kém hơn CET.
- Invalidity:** CET đạt giá trị thấp nhất và ổn định trên cả tập huấn luyện và kiểm thử. Clustering giảm dần nhưng không bằng CET, còn AReS gần như không thay đổi và luôn cao.

Kết quả cho thấy **CET vượt trội hơn** so với AReS và Clustering ở cả ba chỉ số. CET vừa tiết kiệm chi phí, vừa duy trì độ chính xác, đồng thời ổn định hơn khi tăng số hành động phức tạp, nhờ đó thể hiện khả năng *tổng quát hoá* tốt trên tập kiểm thử.




Hình 5.2: Complexity - Logistic Regression - German

CET duy trì chi phí (*Cost*) thấp hơn so với AReS và có xu hướng ổn định hơn Clustering. Về *Loss*, CET thể hiện kết quả thấp và ổn định, trong khi Clustering dao động mạnh và AReS giữ *Loss* thấp nhưng với chi phí rất cao. Chỉ số *Invalidity* của CET luôn thấp hơn hai phương pháp còn lại, đặc biệt ổn định khi số hành động tăng.



Hình 5.3: Complexity - Logistic Regression - Pareto Frontier


Biểu diễn trade-off giữa *Cost* và *Loss* trên hai bộ dữ liệu Diabetes và German. Các điểm của CET nằm gần đường Pareto, chứng tỏ phương pháp này đạt được sự cân bằng tối ưu giữa chi phí và độ chính xác. Ngược lại, AReS tuy có *Loss* thấp nhưng phải đánh đổi bằng *Cost* cao, còn Clustering biến động nhiều và kém ổn định.



Hình 5.4: Complexity - Logistic Regression - Tổng hợp


Kết quả tổng hợp khẳng định rằng CET đạt được sự cân bằng tối ưu giữa *Cost* và *Loss*, đồng thời ổn định hơn trên cả hai bộ dữ liệu, chứng minh tính **tổng quát hoá** và **ưu việt** so với AReS và Clustering.

5.4.2 Complexity (LightGBM)




Hình 5.5: Complexity - LightGBM - Diabetes

CET duy trì chi phí thấp và ổn định khi số hành động tăng, thấp hơn đáng kể so với AReS (luôn cao và gần như không đổi). Về *Loss*, CET thể hiện kết quả ổn định và giảm dần, trong khi Clustering dao động mạnh. AReS có *Loss* thấp nhưng đi kèm với *Cost* cao, dẫn đến hiệu quả tổng thể kém hơn CET. Chỉ số *Invalidity* của CET luôn thấp nhất và ổn định, chứng tỏ phương pháp này cân bằng tốt giữa chi phí và độ chính xác.




Hình 5.6: Complexity - LightGBM - German

CET tiếp tục duy trì chi phí thấp và ổn định, thấp hơn hẳn so với AReS và tốt hơn Clustering. Về *Loss*, CET đạt kết quả thấp và đều đặn, trong khi Clustering biến động nhiều và AReS phải đánh đổi chi phí rất cao để giữ *Loss* nhỏ. Chỉ số *Invalidity* của CET luôn thấp hơn các phương pháp còn lại, chứng minh khả năng **tổng quát hoá** và **ổn định** vượt trội.



Hình 5.7: Complexity - LightGBM - Pareto Frontier


Các điểm của CET thường nằm gần đường Pareto, chứng tỏ phương pháp đạt được sự cân bằng tốt giữa chi phí và độ chính xác. Trên tập Diabetes và German, CET cho thấy giải pháp ổn định và hợp lý hơn so với Clustering (dao động lớn) và AReS (Loss thấp nhưng chi phí rất cao).



Hình 5.8: Complexity - LightGBM - Tổng hợp

CET duy trì *Cost* thấp hơn đáng kể so với AReS, đồng thời ổn định hơn Clustering. Về *Loss*, CET giữ giá trị thấp và ổn định, trong khi Clustering dao động mạnh và AReS tuy thấp nhưng đánh đổi bằng chi phí cao. Kết quả này củng cố rằng CET đạt được sự **cân bằng tối ưu** giữa hiệu quả và khả năng diễn giải.

5.4.3 Convergence (Logistic Regression)




Hình 5.9: Convergence - Logistic Regression - Attrition

Kết quả cho thấy đường màu cam giảm dần và tiến tới trạng thái ổn định, chứng tỏ thuật toán tìm được nghiệm tốt hơn theo thời gian. Mặc dù giá trị hàm mục tiêu (đường xanh) dao động do tính chất ngẫu nhiên của quá trình tối ưu, xu hướng chung vẫn giảm về mức thấp hơn.

- Với $\lambda = 0.01$, thuật toán hội tụ chậm hơn nhưng đạt giá trị mục tiêu cuối cùng thấp.
- Với $\lambda = 0.03$ và 0.05 , hội tụ nhanh hơn và giá trị mục tiêu ổn định sớm hơn.

Kết quả này khẳng định rằng CET có khả năng **hội tụ ổn định** trên nhiều cấu hình siêu tham số, đảm bảo tính **tín cậy** và **khả năng áp dụng thực tế**.




Hình 5.10: Convergence - Logistic Regression - Diabetes

Kết quả cho thấy CET hội tụ ổn định: đường cam giảm dần và tiến tới trạng thái ổn định, dù đường xanh dao động mạnh do bản chất ngẫu nhiên của thuật toán.


- Với $\lambda = 0.01$, quá trình hội tụ chậm và dao động lớn, nhưng giá trị cuối cùng thấp.
- Với $\lambda = 0.03$, tốc độ hội tụ nhanh hơn và giá trị mục tiêu giảm rõ rệt.
- Với $\lambda = 0.05$, ban đầu dao động mạnh nhưng nhanh chóng ổn định về sau.

Như vậy, CET thể hiện khả năng **hội tụ ổn định** và đạt nghiệm tốt trên tập Diabetes, bất kể giá trị λ thay đổi, chứng minh tính **tín cậy** và **bền vững**.

5.4.4 User Study




Hình 5.11: User Study - AReS



Hình 5.12: User Study - Clustering

Kết quả này cho thấy cả hai phương pháp đều có hạn chế: AReS phức tạp, Clustering chưa đủ cá nhân hóa. Đây là cơ sở để so sánh và nhấn mạnh ưu điểm của **CET**, vốn kết hợp được tính trực quan của cấu trúc cây với khả năng gợi ý hành động cá nhân hóa và chi phí thấp.



Hình 5.13: User Study - CET

Mỗi hành động ($Bad \rightarrow Good$) được mô tả kèm theo:

- Tỷ lệ mẫu thoả mãn điều kiện.
- Chi phí trung bình của hành động ($MeanCost$).
- Các thay đổi cụ thể trên đặc trưng (Glucose, BMI, BloodPressure).

So sánh với AReS, CET duy trì cấu trúc cây nhưng gọn gàng và dễ hiểu hơn. So sánh với Clustering, CET cung cấp hành động cá nhân hóa hơn, không chỉ dừng lại ở hành động chung cho từng cụm.

Kết quả này cho thấy CET kết hợp được **tính trực quan** và **tính cá nhân hóa**, đồng thời cung cấp chỉ số chi phí và tỷ lệ minh bạch, giúp tăng mức độ tin cậy của người dùng.

Chương 6

Kết luận và Định hướng nghiên cứu

6.1 Tóm tắt các phát hiện và đóng góp chính

Counterfactual Explanation Tree (CET) được nghiên cứu giới thiệu là một cây quyết định có khả năng gán hành động phản thực hiệu quả cho từng đầu vào trên toàn bộ không gian dữ liệu. Các đóng góp chính bao gồm:

- Giới thiệu **CET (Counterfactual Explanation Tree)**, một cây quyết định có khả năng gán hành động thay đổi kết quả đầu ra một cách hiệu quả cho từng đầu vào trên toàn bộ không gian dữ liệu. CET tận dụng cấu trúc cây quyết định (Decision Tree) để (1) cung cấp quy trình **minh bạch** (Transparency) trong việc gán hành động, và (2) gán duy nhất một cặp *hành động và lý do* cho mỗi cá thể để đảm bảo tính nhất quán trên toàn bộ tập dữ liệu.
- Xây dựng phương pháp học CET từ một tập dữ liệu cho trước, giải quyết bài toán tối ưu hóa bằng thuật toán **Stochastic Local Search**, kết hợp chiến lược pruning dựa trên ràng buộc mục tiêu.
- Thử nghiệm trên các tập dữ liệu công khai để đánh giá hiệu quả của CET so với các phương pháp hiện có. Ngoài ra, qua các nghiên cứu về người dùng, kết quả cho thấy CET dễ hiểu và trực quan đối với người dùng hơn.

6.2 Ưu điểm và hạn chế của phương pháp

Ưu điểm:

- **Minh bạch và nhất quán:** CET tận dụng cấu trúc cây quyết định để gán duy nhất một cặp *hành động + lý do* cho mỗi cá thể, tránh tình trạng gán nhiều hành động hoặc thiếu bao phủ như trong AReS.
- **Phủ toàn cục:** Khác với CE cục bộ, CET đảm bảo phân vùng toàn bộ không gian đầu vào và đưa ra một bản tóm tắt toàn cục đáng tin cậy.
- **Dễ hiểu với người dùng:** Kết quả khảo sát người dùng cho thấy CET trực quan và dễ diễn giải hơn so với các phương pháp tổng hợp toàn cục khác.

Hạn chế:

- **Giới hạn về khả năng biểu đạt:** Do chỉ sử dụng một cây quyết định, CET có thể gặp khó khăn trong việc mô tả các quan hệ phi tuyến phức tạp, nơi mà các mô hình ensemble thường vượt trội hơn.
- **Chi phí tính toán:** Việc học CET được mô hình hóa như một bài toán tối ưu hóa toàn cục và giải bằng *Stochastic Local Search* kết hợp với pruning. Do đó, khi dữ liệu có số chiều lớn hoặc nhiều mẫu, chi phí tính toán có thể tăng đáng kể.

6.3 Ý nghĩa đối với lĩnh vực

CET mở ra một hướng tiếp cận mới trong việc tổng hợp các giải thích phản thực: vừa đảm bảo **minh bạch** và **nhất quán**, vừa có thể áp dụng cho toàn bộ không gian đầu vào. Điều này đặc biệt có ý nghĩa trong các lĩnh vực nhạy cảm như **tài chính**, **y tế**, và **pháp lý**, nơi mà người dùng không chỉ cần dự đoán chính xác mà còn phải hiểu rõ *những hành động khả thi để thay đổi kết quả mô hình*. Bằng việc cung cấp cả góc nhìn cục bộ lẫn toàn cục một cách rõ ràng, CET góp phần thu hẹp khoảng cách giữa *hiệu quả mô hình* và *khả năng giải thích*, giúp tăng niềm tin của người dùng vào các hệ thống học máy.

6.4 Định hướng nghiên cứu trong tương lai

Các hướng nghiên cứu trong tương lai có thể bao gồm:

- **Mở rộng CET cho dữ liệu phi tuyến và nhiều đặc trưng:** áp dụng các kỹ thuật phân nhánh phức tạp hơn hoặc kết hợp với học sâu.
- **Tối ưu hóa hiệu năng:** giảm thời gian tính toán khi áp dụng CET trên các tập dữ liệu lớn.
- **Kết hợp với các loại giải thích khác:** tích hợp CE với SHAP hoặc LIME để tăng cường độ chính xác và khả năng minh bạch (SHAP/LIME có thể giúp xác định đặc trưng quan trọng nhất cần thay đổi, từ đó giảm chi phí tìm kiếm hành động CE).

Tài liệu tham khảo

- [1] F. Doshi-Velez and B. Kim, *Towards A Rigorous Science of Interpretable Machine Learning*, 2017. arXiv: 1702.08608 [stat.ML]. address: <https://arxiv.org/abs/1702.08608>.
- [2] S. Wachter, B. Mittelstadt, and C. Russell, *Counterfactual Explanations without Opening the Black Box: Automated Decisions and the GDPR*, 2018. arXiv: 1711.00399 [cs.AI]. address: <https://arxiv.org/abs/1711.00399>.
- [3] B. Ustun, A. Spangher, and Y. Liu, “Actionable Recourse in Linear Classification”, in *Proceedings of the Conference on Fairness, Accountability, and Transparency*, ser. FAT* ’19, ACM, Jan. 2019, pp. 10–19. DOI: 10.1145/3287560.3287566. address: <http://dx.doi.org/10.1145/3287560.3287566>.
- [4] Kaggle, *IBM HR Analytics Employee Attrition & Performance*, <https://www.kaggle.com/pavansubhasht/ibm-hr-analytics-attrition-dataset>, 2017.
- [5] M. T. Ribeiro, S. Singh, and C. Guestrin, “Anchors: High-Precision Model-Agnostic Explanations”, in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 32, 2018, pp. 1527–1535. DOI: 10.1609/aaai.v32i1.11491. address: <https://doi.org/10.1609/aaai.v32i1.11491>.
- [6] J. Chen, L. Song, M. J. Wainwright, and M. I. Jordan, *Learning to Explain: An Information-Theoretic Perspective on Model Interpretation*, 2018. arXiv: 1802.07814 [cs.LG]. address: <https://arxiv.org/abs/1802.07814>.
- [7] L. Breiman, J. H. Friedman, R. A. Olshen, and C. J. Stone, “Classification and Regression Trees”, *Biometrics*, vol. 40, p. 874, 1984. address: <https://api.semanticscholar.org/CorpusID:29458883>.
- [8] J. R. Quinlan, “Induction of Decision Trees”, *Machine Learning*, vol. 1, pp. 81–106, 1986. address: <https://api.semanticscholar.org/CorpusID:189902138>.
- [9] X. Hu, C. Rudin, and M. I. Seltzer, “Optimal Sparse Decision Trees”, in *Neural Information Processing Systems*, 2019. address: <https://api.semanticscholar.org/CorpusID:139104649>.
- [10] G. Aglin, S. Nijssen, and P. Schaus, “Learning Optimal Decision Trees Using Caching Branch-and-Bound Search”, *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 34, no. 04, pp. 3146–3153, 2020. DOI: 10.1609/aaai.v34i04.5711. address: <https://ojs.aaai.org/index.php/AAAI/article/view/5711>.
- [11] A.-H. Karimi, G. Barthe, B. Schölkopf, and I. Valera, *A survey of algorithmic recourse: definitions, formulations, solutions, and prospects*, 2021. arXiv: 2010.04050 [cs.LG]. address: <https://arxiv.org/abs/2010.04050>.
- [12] K. Kanamori, T. Takagi, K. Kobayashi, and Y. Ike, “Counterfactual Explanation Trees: Transparent and Consistent Actionable Recourse with Decision Trees”, in *Proceedings of the 25th International Conference on Artificial Intelligence and Statistics*, 2022, pp. 1846–1870.
- [13] L. Schut, O. Key, R. McGrath, L. Costabello, B. Sacaleanu, M. Corcoran, and Y. Gal, *Generating Interpretable Counterfactual Explanations By Implicit Minimisation of Epistemic and Aleatoric Uncertainties*, 2021. arXiv: 2103.08951 [cs.LG]. address: <https://arxiv.org/abs/2103.08951>.
- [14] R. K. Mothilal, A. Sharma, and C. Tan, “Explaining machine learning classifiers through diverse counterfactual explanations”, in *Proceedings of the 2020 Conference on Fairness, Accountability, and Transparency*, ser. FAT* ’20, Barcelona, Spain: Association for Computing Machinery, 2020, 607–617, ISBN: 9781450369367. DOI: 10.1145/3351095.3372850. address: <https://doi.org/10.1145/3351095.3372850>.
- [15] K. Rawal and H. Lakkaraju, *Beyond Individualized Recourse: Interpretable and Interactive Summaries of Actionable Recourses*, 2020. arXiv: 2009.07165 [cs.LG]. address: <https://arxiv.org/abs/2009.07165>.
- [16] K. N. Ramamurthy, B. Vinzamuri, Y. Zhang, and A. Dhurandhar, *Model Agnostic Multilevel Explanations*, 2020. arXiv: 2003.06005 [cs.LG]. address: <https://arxiv.org/abs/2003.06005>.
- [17] J. Gao, X. Wang, Y. Wang, Y. Yan, and X. Xie, “Learning Groupwise Explanations for Black-Box Models.”, in *IJCAI*, 2021, pp. 2396–2402.

- [18] S. Russell and P. Norvig, *Artificial Intelligence, Global Edition A Modern Approach*. Pearson Deutschland, 2021, p. 1168, ISBN: 9781292401133. address: <https://elibrary.pearson.de/book/99.150005/9781292401171>.
- [19] A. Freitas, “Comprehensible classification models: A position paper”, *ACM SIGKDD Explorations Newsletter*, vol. 15, pp. 1–10, Mar. 2014. DOI: 10.1145/2594473.2594475.
- [20] R. Guidotti, A. Monreale, S. Ruggieri, F. Turini, D. Pedreschi, and F. Giannotti, *A Survey Of Methods For Explaining Black Box Models*, 2018. arXiv: 1802.01933 [cs.CY]. address: <https://arxiv.org/abs/1802.01933>.
- [21] B. Becker and R. Kohavi, *Adult*, UCI Machine Learning Repository, DOI: <https://doi.org/10.24432/C5XW20>, 1996.
- [22] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, “LightGBM: A Highly Efficient Gradient Boosting Decision Tree”, Dec. 2017.