

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN

Cây giải thích phản thực
Báo cáo nghiên cứu Cây quyết định

Trương Quốc Cường – 23127333
Trần Cẩm Huy – 23127056
Nguyễn Tấn Phát – 23127449
Lưu Huy Minh Quang – 23127016

Ngày 3 tháng 9 năm 2025

- ➊ **Nền tảng: Giải thích phản thực (CE)**
- ➋ Mục tiêu nghiên cứu
- ➌ Tổng quan đóng góp
- ➍ Đề xuất: Counterfactual Explanation Tree (CET)
- ➎ Thực nghiệm và kết quả
- ➏ Kết luận

Nền tảng: Giải thích phản thực (CE)

Giải thích "hành động" để đạt được kết quả dự đoán mong muốn

Phương pháp giải thích hậu nghiệm để đưa ra các **giải thích cục bộ** cho một bộ phân loại.

Giải thích phản thực: Đối với mỗi trường hợp $x \in \mathcal{X}$, CE tìm một **hành động** a^* sao cho kết quả dự đoán của **bộ phân loại** $f : \mathcal{X} \rightarrow \mathcal{Y}$ **thay đổi thành nhãn mục tiêu** $y^* \in \mathcal{Y}$, đồng thời tối thiểu hóa chi phí thực hiện hành động:

$$a^* = \arg \min_{a \in \mathcal{A}} c(a|x) \quad \text{với điều kiện} \quad f(x + a) = y^*$$

hàm chi phí
(Max Percentile Shift (Ustun and others 2019))

- ① Nền tảng: Giải thích phản thực (CE)
- ② Mục tiêu nghiên cứu
- ③ Tổng quan đóng góp
- ④ Đề xuất: Counterfactual Explanation Tree (CET)
- ⑤ Thực nghiệm và kết quả
- ⑥ Kết luận

Mục tiêu nghiên cứu: Giải thích phản thực cho “nhiều” trường hợp

Gán hành động cho nhiều trường hợp $X \subset \mathcal{X}$ đồng thời

Các hành động a tối ưu cho từng cá thể x **không nhất thiết** do chính cá thể đó thực hiện (Karimi **and others** 2021).

Ví dụ: Dự đoán nguy cơ nghỉ việc. Một công ty gán các hành động cho nhân viên để giảm nguy cơ nghỉ việc.

Một hành động a cho một cá thể x (ví dụ: tăng lương) **có thể ảnh hưởng đến các cá thể khác** (ví dụ: thay đổi hệ thống lương trong công ty).

⇒ Trong trường hợp này, việc tối ưu hành động riêng lẻ cho từng cá thể là chưa đủ.

- 1 Nền tảng: Giải thích phản thực (CE)
- 2 Mục tiêu nghiên cứu
- 3 Tổng quan đóng góp**
- 4 Đề xuất: Counterfactual Explanation Tree (CET)
- 5 Thực nghiệm và kết quả
- 6 Kết luận

Một framework CE mới có khả năng gán hành động cho nhiều trường hợp

Nghiên cứu đề xuất **Cây Giải thích phản thực (CET)**, có khả năng gán hành động cho các trường hợp đầu vào bằng **cây quyết định**.

Đặc tính:

- **Tính minh bạch:** Giải thích được hành động áp dụng cho tất cả các trường hợp trong không gian đầu vào.
- **Tính nhất quán:** Không tồn tại xung đột trong lý do gán hành động giữa các trường hợp.

- 1 Nền tảng: Giải thích phản thực (CE)
- 2 Mục tiêu nghiên cứu
- 3 Tổng quan đóng góp
- 4 Đề xuất: Counterfactual Explanation Tree (CET)
- 5 Thực nghiệm và kết quả
- 6 Kết luận

Định nghĩa và Ưu điểm của CET

CET: Cây quyết định gán hành động hiệu quả trên toàn bộ không gian đầu vào

Định nghĩa: Với một tập hành động khả thi $\mathcal{A}$, **Counterfactual Explanation Tree (CET)** là cây quyết định $h : \mathcal{X} \rightarrow \mathcal{A}$ gán hành động cho mỗi trường hợp $x \in \mathcal{X}$.

Ưu điểm:

- Giải thích mỗi hành động dưới dạng *quy tắc* (minh bạch).
- Gán duy nhất một cặp (*hành động, quy tắc*) cho mỗi trường hợp (nhất quán).

Xây dựng Counterfactual Explanation Tree (CET)

CET từ điểm không hợp lệ (Invalidity score)

$$i_{\gamma}(a \mid x) := c(a \mid x) + \gamma \cdot \ell(f(x + a), y^*)$$

Trong đó:

- $c(a \mid x)$: **Chi phí** thực hiện hành động a .
- $\ell(f(x + a), y^*)$: **Hàm mất mát** liên quan đến ràng buộc $f(x + a) = y^*$.
- Hành động $a = h(x)$ được coi là *hiệu quả* nếu chi phí thấp và đạt kết quả mong muốn.

Tối ưu CET qua stochastic local search

Hàm chi phí tổng quát:

$$o_{\gamma,\lambda}(h \mid X) := \frac{1}{|X|} \sum_{x \in X} i_{\gamma}(h(x) \mid x) + \lambda |\mathcal{L}(h)|$$

Trong đó:

- $i_{\gamma}(a \mid x) = c(a \mid x) + \gamma \ell(f(x + a), y^*)$ là **invalidity score**.
- $|\mathcal{L}(h)|$: số lá trong CET (số hành động được gán).
- λ : điều chỉnh **độ phức tạp của cây** và **trade-off** giữa hiệu quả hành động và tính diễn giải.
- Tối ưu: $h^* = \arg \min_{h \in \mathcal{H}} o_{\gamma,\lambda}(h \mid X)$.

Định lý 1: Giới hạn số lá của CET

Kích thước cây tối ưu bị chặn trên bởi tham số γ, λ

$$|\mathcal{L}(h^*)| \leq \frac{\gamma + \lambda}{\lambda}$$

Ý nghĩa:

- Số lá của CET tối ưu h^* luôn bị chặn trên bởi $\frac{\gamma + \lambda}{\lambda}$.
- Cho thấy sự phụ thuộc trực tiếp giữa độ phức tạp của cây và tham số trade-off.

Định lý 2: Tính tối ưu cục bộ trong các lá CET

Mỗi lá trong CET chứa hành động tối ưu với chi phí và invalidity thấp nhất cho các trường hợp thuộc lá đó.

$$a_{\ell}^* = \arg \min_{a \in \mathcal{A}(x_{\ell})} \sum_{x \in x_{\ell}} i_{\gamma}(a \mid x)$$

Ý nghĩa:

- Tối ưu cục bộ đảm bảo hành động tại mỗi lá vừa hiệu quả vừa thỏa ràng buộc CE.
- Giúp cây giữ tính minh bạch, vì mỗi lá áp dụng một quy tắc rõ ràng.

Định lý 3: Tính phân rã hợp lý của CET

CET có thể được phân rã thành các lá không giao nhau, đảm bảo các quy tắc hành động không xung đột.

$$X = \bigcup_{\ell \in \mathcal{L}(h)} X_{\ell}, \quad X_{\ell} \cap X_{\ell'} = \emptyset \quad \forall \ell \neq \ell'$$

Ý nghĩa:

- Mỗi cá thể $x \in X$ chỉ thuộc một lá duy nhất.
- Giúp tránh xung đột hành động và đảm bảo tính nhất quán.

Ý tưởng: Cập nhật các quy tắc phân nhánh trong cây CET hiện tại $h^{(t)}$ bằng một số thao tác ngẫu nhiên.

Các thao tác chỉnh sửa:

- *insert*: chèn thêm một nút phân nhánh
- *delete*: xoá một nút phân nhánh
- *replace*: thay thế quy tắc tại một nút

Bước con (subroutine): Hành động gán cho các lá được tối ưu bằng cách giải MILO mở rộng (Ustun **and others** 2019; Kanamori **and others** 2022).

Tham khảo: Wang 2019; Pan **and others** 2020

Mã giả Tìm kiếm cục bộ ngẫu nhiên I

Require: Tập các mẫu X , tham số cân bằng γ, λ , tập các luật phân nhánh ứng viên $\mathcal{R}$, số vòng lặp tối đa T , và điều kiện chấp nhận ACCEPT

Ensure: CET h^*

- 1: $h^{(0)} \leftarrow$ Sinh ngẫu nhiên một nghiệm khởi tạo
- 2: $h^* \leftarrow h^{(0)}$
- 3: **for** $t = 1, 2, \dots, T$ **do**
- 4: $\delta \sim \text{RANDOM}()$
- 5: **if** $\delta \leq 1/3$ **và** $|\mathcal{L}(h^{(t-1)})| < (\gamma + \lambda)/\lambda$ **then**
- 6: $h^{(t)} \leftarrow$ Chèn ngẫu nhiên một nút với một luật $r \in \mathcal{R}$ vào $h^{(t-1)}$
- 7: **else if** $\delta \leq 2/3$ **then**
- 8: $h^{(t)} \leftarrow$ Xóa ngẫu nhiên một nút từ $h^{(t-1)}$
- 9: **else**

Mã giả Tìm kiếm cục bộ ngẫu nhiên II

```
10:       $h^{(t)} \leftarrow$  Thay thế ngẫu nhiên luật của một nút trong  $h^{(t-1)}$   
      bằng một luật khác  $r \in \mathcal{R}$   
11:      end if  
12:      for  $\ell \in \mathcal{L}(h^{(t)})$  do  
13:           $a_{\ell}^{(t)} \leftarrow \arg \min_{a \in A(X_{\ell}^{(t)})} g_{\gamma} \left( a \mid X_{\ell}^{(t)} \right)$   
14:      end for  
15:      if  $\text{ACCEPT}(t, h^{(t-1)}, h^{(t)})$  là False then  
16:           $h^{(t)} \leftarrow h^{(t-1)}$   
17:      end if  
18:       $h^* \leftarrow \arg \min_{h \in \{h^*, h^{(t)}\}} o_{\gamma, \lambda}(h \mid X)$   
19: end for  
20: return  $h^*$ 
```

- ① Nền tảng: Giải thích phản thực (CE)
- ② Mục tiêu nghiên cứu
- ③ Tổng quan đóng góp
- ④ Đề xuất: Counterfactual Explanation Tree (CET)
- ⑤ Thực nghiệm và kết quả
- ⑥ Kết luận

CET có thể gán hành động hiệu quả theo cách dễ diễn giải


So sánh với AReS (Rawal and Lakkaraju 2020) dựa trên **rule set**:

- **Định lượng:** hiệu quả của hành động (cost, loss, invalidity).
- **Định tính:** mức độ dễ diễn giải với người dùng (user study).



Kết quả:


- CET gán hành động **hiệu quả hơn** AReS về chi phí, mất mát và invalidity, đồng thời vẫn đảm bảo minh bạch và nhất quán.
- Hành vi của CET dễ dàng được người dùng hiểu.
- **CET đạt được hành động hiệu quả và có thể diễn giải!**

Minh họa khả năng diễn giải



Minh họa khả năng diễn giải





Kết quả thực nghiệm chi tiết

So sánh Cost, Loss, Invalidity:

Dataset	Method	Cost	Loss	Invalidity
Train	AReS	0.436 ± 0.06	0.435 ± 0.07	0.871 ± 0.04
	CET	0.349 ± 0.1	0.4 ± 0.11	0.749 ± 0.05
Test	AReS	0.45 ± 0.08	0.298 ± 0.09	0.748 ± 0.09
	CET	0.383 ± 0.12	0.318 ± 0.09	0.701 ± 0.12

So sánh User Accuracy và Thời gian:

Method	User Acc.	Time [s]
AReS	95.12%	784.8 ± 202
CET	100.0%	674.0 ± 392

Kết luận: Kết quả thực nghiệm khác với công bố gốc, chủ yếu do nhóm giảm bớt các tham số và hạn chế về cấu hình máy. Tuy nhiên, kết quả vẫn phản ánh đúng xu hướng phương pháp và cần được kiểm chứng thêm với điều kiện tối ưu hơn.

Thực nghiệm (IBM Attrition dataset) – AReS (Rawal and Lakkaraju 2020)

Rule	Action
If OverTime=True AND Performance=False	OverTime=False
If BusinessTravel=1 AND OverTime=False	BusinessTravel<1 AND OverTime=False
If JobLevel<2 AND MonthlyIncome<2275	MonthlyIncome $\geq$ 15170 AND OverTime=False
If OverTime=True AND $2 \leq \text{YearsInCurrentRole} < 3$	MonthlyIncome $\geq$ 15170 AND OverTime=False
Default	MonthlyIncome $\geq$ 15170 AND OverTime=False

Cost: 47.0%

Loss: 8.7%

User Acc.: 95.1%

Time: 784.8 sec.

Thực nghiệm (IBM Attrition dataset) – CET (Ours)

Rule	Action
If OverTime=True	OverTime=False
If YearsInCurrentRole < 1	BusinessTravel=-1, MonthlyIncome+=8502
If OverTime=False AND YearsInCurrentRole ≥ 1	MonthlyIncome+=2276, OverTime=False
If OverTime=True AND YearsInCurrentRole ≥ 1	BusinessTravel=-1, MonthlyIncome+=2231
Else	OverTime=False, PercentSalaryHike+=1

Cost: 41.0%

Loss: 4.3%

User Acc.: 100%

Time: 674.0 sec.

- ① Nền tảng: Giải thích phản thực (CE)
- ② Mục tiêu nghiên cứu
- ③ Tổng quan đóng góp
- ④ Đề xuất: Counterfactual Explanation Tree (CET)
- ⑤ Thực nghiệm và kết quả
- ⑥ Kết luận

CET: Framework hiệu quả cho giải thích phản thực toàn cục

- Đề xuất CET như một giải pháp cho vấn đề CE đa trường hợp
- Đảm bảo tính minh bạch, nhất quán và phủ toàn cục
- Thuật toán hiệu quả dựa trên stochastic local search
- Thực nghiệm cho thấy hiệu quả vượt trội so với AReS

- [1] B. Ustun, A. Spangher **and** Y. Liu, “Actionable Recourse in Linear Classification,” *in Proceedings of the Conference on Fairness, Accountability, and Transparency* **jourser** FAT* '19, ACM, **january** 2019, 10–19. DOI: 10.1145/3287560.3287566. **url:** <http://dx.doi.org/10.1145/3287560.3287566>.
- [2] A.-H. Karimi, G. Barthe, B. Schölkopf **and** I. Valera, *A survey of algorithmic recourse: definitions, formulations, solutions, and prospects*, 2021. arXiv: 2010.04050 [cs.LG]. **url:** <https://arxiv.org/abs/2010.04050>.
- [3] K. Kanamori, T. Takagi, K. Kobayashi **and** Y. Ike, “Counterfactual Explanation Trees: Transparent and Consistent Actionable Recourse with Decision Trees,” *in Proceedings of the 25th International Conference on Artificial Intelligence and Statistics 2022*, **pages** 1846–1870.

- [4] T. Wang, *Gaining Free or Low-Cost Transparency with Interpretable Partial Substitute*, 2019. arXiv: 1802.04346 [cs.LG]. **url:** <https://arxiv.org/abs/1802.04346>.
- [5] D. Pan, T. Wang **and** S. Hara, *Interpretable Companions for Black-Box Models*, 2020. arXiv: 2002.03494 [stat.ML]. **url:** <https://arxiv.org/abs/2002.03494>.
- [6] K. Rawal **and** H. Lakkaraju, *Beyond Individualized Recourse: Interpretable and Interactive Summaries of Actionable Recourses*, 2020. arXiv: 2009.07165 [cs.LG]. **url:** <https://arxiv.org/abs/2009.07165>.